



Home Credit Default Risk Prediction

Predicting Default Probability Using Machine Learning


Presented by

Made Agata Purwananda

**Data Science Project-Based Internship –
Rakamin Academy x Home Credit Indonesia**

Problem Statement

- **Konteks:** Institusi keuangan menghadapi risiko tinggi saat meminjamkan dana kepada klien tanpa riwayat kredit tradisional yang cukup.
- **Tujuan Bisnis:** Membangun model machine learning yang tangguh untuk memprediksi kemampuan bayar klien secara akurat.
- **Dampak yang Diharapkan:** Meminimalkan penolakan terhadap klien yang sebenarnya mampu membayar (meningkatkan revenue), sekaligus menekan risiko kredit macet (meminimalkan kerugian).



1. Dataset Overview

- **Data Utama (Demografi & Target):** Berasal dari `application_train.csv` (307.511 baris). Ditemukan bahwa data sangat imbalanced: 91,9% pengajuan lancar (0) dan hanya 8,1% yang berisiko macet (1).
- **Data Relasional (Histori Kredit):**
 - **bureau.csv:** Menambahkan riwayat pinjaman klien di institusi keuangan/bank lain.
 - **previous_application.csv:** Menambahkan riwayat pengajuan pinjaman klien di Home Credit sebelumnya.
- **Hasil Penggabungan:** Menghasilkan 135 fitur analitik yang kaya dan komprehensif.

2. Data Pre-Processing & Anomaly Handling

- **Edge Case Mitigation:** Ditemukan anomali ekstrem berupa nilai 365243 hari (sekitar 1000 tahun) pada kolom DAYS_EMPLOYED. Nilai ini diubah menjadi NaN agar tidak merusak distribusi (*skewness*) statistik umur.
- **Feature Engineering Waktu:** Mengonversi nilai waktu negatif pada DAYS_BIRTH dan DAYS_EMPLOYED menjadi umur dalam satuan *Tahun* (positif) agar lebih mudah diinterpretasikan oleh model dan tim bisnis.
- **Enterprise-Grade Pipeline:** Menggunakan ColumnTransformer (Scikit-Learn) untuk otomatisasi imputasi Median & StandardScaler pada data numerik, serta imputasi Mode & OneHotEncoder pada data kategorikal

3. Bussiness Insight 1 – Kelompok Anomali “365243”

- **Insight:** Nilai anomali 365243 pada fitur DAYS_EMPLOYED bukan sekadar *error* sistem, melainkan *default marker* yang biasanya merepresentasikan kelompok klien Pensiunan (Retirees) atau mereka yang sudah tidak memiliki pekerjaan formal.
- **Actionable Recommendation:** Daripada menolak kelompok ini karena dianggap "tidak memiliki penghasilan tetap", Home Credit dapat merancang produk khusus bernama "Senior/Pensioner Credit". Limit pinjaman untuk segmen ini tidak dinilai dari slip gaji bulanan, melainkan dari rasio kepemilikan aset pendukung atau nilai penjaminan (*collateral*).

4. Bussiness Insight 2 – Perilaku Histori Pinjaman

- **Insight:** Proporsi klien gagal bayar tertinggi berasal dari klien yang tidak memiliki jejak data di bureau.csv maupun previous_application.csv (Blank Credit History/Unbanked). Sebaliknya, klien dengan jumlah riwayat sukses di masa lalu memiliki tingkat gagal bayar yang sangat rendah.
- **Actionable Recommendation:** Implementasikan sistem Fast-Track Auto-Approval (Persetujuan Otomatis Cepat). Jika seorang klien baru terdeteksi memiliki histori sukses di bureau.csv, mereka dapat melompati verifikasi manual panjang dan langsung mendapatkan pencairan dana. Ini akan meningkatkan *Customer Experience* secara signifikan.

5. Algoritma & Pemodelan Machine Learning

- **Metodologi:** Data dibagi (Train-Test Split) dengan teknik *Stratify* untuk menjaga rasio imbalanced 91:8 tetap stabil di data uji. Mengaktifkan `class_weight='balanced'` pada algoritma.
- **Model yang Dikembangkan:**
 - **Logistic Regression:** Bertindak sebagai *baseline model* karena unggul dalam interpretabilitas bisnis.
 - **Random Forest Classifier:** Digunakan untuk menangkap pola non-linear yang kompleks dan mengekstrak *Feature Importance*.

6. Evaluasi Performa Model (ROC-AUC)

- **Logistic Regression:** Menghasilkan skor ROC-AUC sebesar 0.7510 (75.1%).
- **Random Forest Classifier:** Menghasilkan skor ROC-AUC sebesar 0.7352 (73.5%).
- **Keputusan Model Final:** Logistic Regression terpilih sebagai model terbaik. Selain performa ROC-AUC-nya lebih tinggi, Logistic Regression memberikan probabilitas yang lebih stabil dan metrik inferensi yang lebih mudah dijelaskan kepada *stakeholder* non-teknis.

7. Feature Importance & Bussiness Strategy

- Berdasarkan ekstraksi dari algoritma, fitur yang paling menentukan kemampuan bayar klien adalah:
 1. **DAYS_BIRTH_YEARS (Umur Klien)**
 2. **DAYS_EMPLOYED_YEARS (Masa Kerja)**
 3. **Histori Pinjaman Eksternal (Data Biro)**
- **Rekomendasi Bisnis Lanjutan:** Tim *Risk Management* (Manajemen Risiko) disarankan untuk memperbesar bobot/skor kriteria *Credit Scoring* manual pada metrik usia produktif dan stabilitas durasi kerja, karena kedua faktor tersebut terbukti secara matematis menjadi benteng terkuat melawan gagal bayar.

Tautan Repositori Portofolio

Isi Repositori:

- Jupyter Notebook (Home Credit_Scorecard_Model.ipynb) berisi dokumentasi EDA, *feature engineering*, dan *pipeline model*.
- Dokumentasi *Enterprise-Grade README* dengan pedoman reproduksi lokal.

4. Dashboard Performance Analytics

Explain Your Result Here

<You should **explain your strategy** on this page and you can add **image or link** result. You can add an explanation of how you got the result also.>

Thank You



Logo Company